




(a) pass@1 par époque




(b) pass@1 par trajectoires



(c) reward train par époque



(d) reward train par trajectoires



— G=8 · 8 tâches, ancre /4 ép. (exp25)

— G=8 · 8 tâches, ancre /8 ép. (exp41)

— G=16 · 8 tâches = 128 traj/pas, ancre /4 ép. (exp39)

— G=16 · 4 tâches, k3 borné (exp43, en cours)

— Horizon · G=16, 4 tâches (exp32)

— Budget · G=16, 4 tâches (exp35)

— Profondeur · G=16, 4 tâches (exp33.1)

Pointillé fin : reprise depuis le best après purge (Profondeur → exp33.2 à l'ép. 44,5 ; exp25 → exp25.2 à l'ép. 111).

Une époque à G=16 = 2× les trajectoires et ≈ 2× le temps GPU d'une époque à G=8.

Reward train d'Horizon : épisodes plafonnés à 10 puis 20 tours jusqu'à l'ép. 30 (plus durs) ; Profondeur : recettes faciles d'abord (reward saturé au départ).